Занятие 3. Обучение без учителя: кластеризация, снижение размерности и аномалии

Что делать, когда нет размеченных данных: структура, сжатие признаков и поиск аномалий

KMeans DBSCAN PCA t-SNE / UMAP Isolation Forest

Листайте слайды стрелками ← →

Цели занятия

- Понять, чем обучение без учителя отличается от обучения с учителем.
- Разобрать задачу кластеризации и основные методы: KMeans, DBSCAN, иерархическая кластеризация.
- Научиться осторожно оценивать качество кластеризации.
- Разобрать снижение размерности: PCA, t-SNE, UMAP и другие методы визуализации.
- Познакомиться с обнаружением аномалий и его ролью в задачах безопасности.

Программа занятия

Теория

- Когда применяется обучение без учителя
- Кластеризация: KMeans, DBSCAN, иерархическая
- Оценка качества кластеризации
- Снижение размерности: PCA, t-SNE, UMAP, TriMAP, PaCMAP
- Обнаружение аномалий

Практика

- Кластеризация make_blobs / Iris / Wine без меток
- Сравнение KMeans и DBSCAN
- PCA и визуализация в 2D
- Поиск аномалий: Isolation Forest, LOF

Повторение: с учителем и без учителя

Обучение с учителем

- Есть признаки X и ответы y.
- Модель учится предсказывать y по X.
- Качество измеряется по известным ответам.

Обучение без учителя

- Есть только признаки X.
- Ответов нет: ищем структуру в самих данных.
- Качество оценить гораздо сложнее.

Когда применяется обучение без учителя

- Нет целевой переменной: разметка дорога или невозможна.
- Нужно найти структуру в данных: группы, сегменты, состояния системы.
- Нужно сжать признаки: уменьшить размерность без сильной потери информации.
- Нужно найти аномалии: редкие и подозрительные объекты (отличающиеся от "нормы").
- Нужно подготовить данные для дальнейшего анализа или других моделей.

Примеры задач без учителя

Сегментация/Кластеризация

Группировка клиентов, пользователей, типов событий, режимов работы системы.

Сжатие и визуализация

Показать многомерные данные в 2D/3D, убрать шум и коррелирующие признаки.

Поиск аномалий

Подозрительная активность, сбои, атаки, нестандартные запросы к модели.

Что значит «обучаться» без ответов

- Мы не минимизируем ошибку предсказания ответа — ответа просто нет.
- Мы ищем закономерности: близость объектов, направления наибольшей изменчивости, редкость.
- Результат часто интерпретирует человек, а не метрика.

Главная сложность обучения без учителя: **отсутствие объективного критерия успеха**.

Кластеризация: постановка задачи

- Даны объекты с признаками X.
- Нужно разбить их на группы (кластеры).
- Объекты внутри одного кластера похожи друг на друга.
- Объекты из разных кластеров отличаются.

```
похожие объекты → в одну группу, непохожие → в разные
```

Схожесть объектов и расстояние

- «Похожесть» формализуется через расстояние между объектами.
- Чем меньше расстояние, тем похожие объекты.
- В основе лежит гипотеза компактности: близкие объекты ведут себя похоже.

```
rho(x_i, x_j) — расстояние между объектами i и j
```

Какие расстояния используют

Евклидово

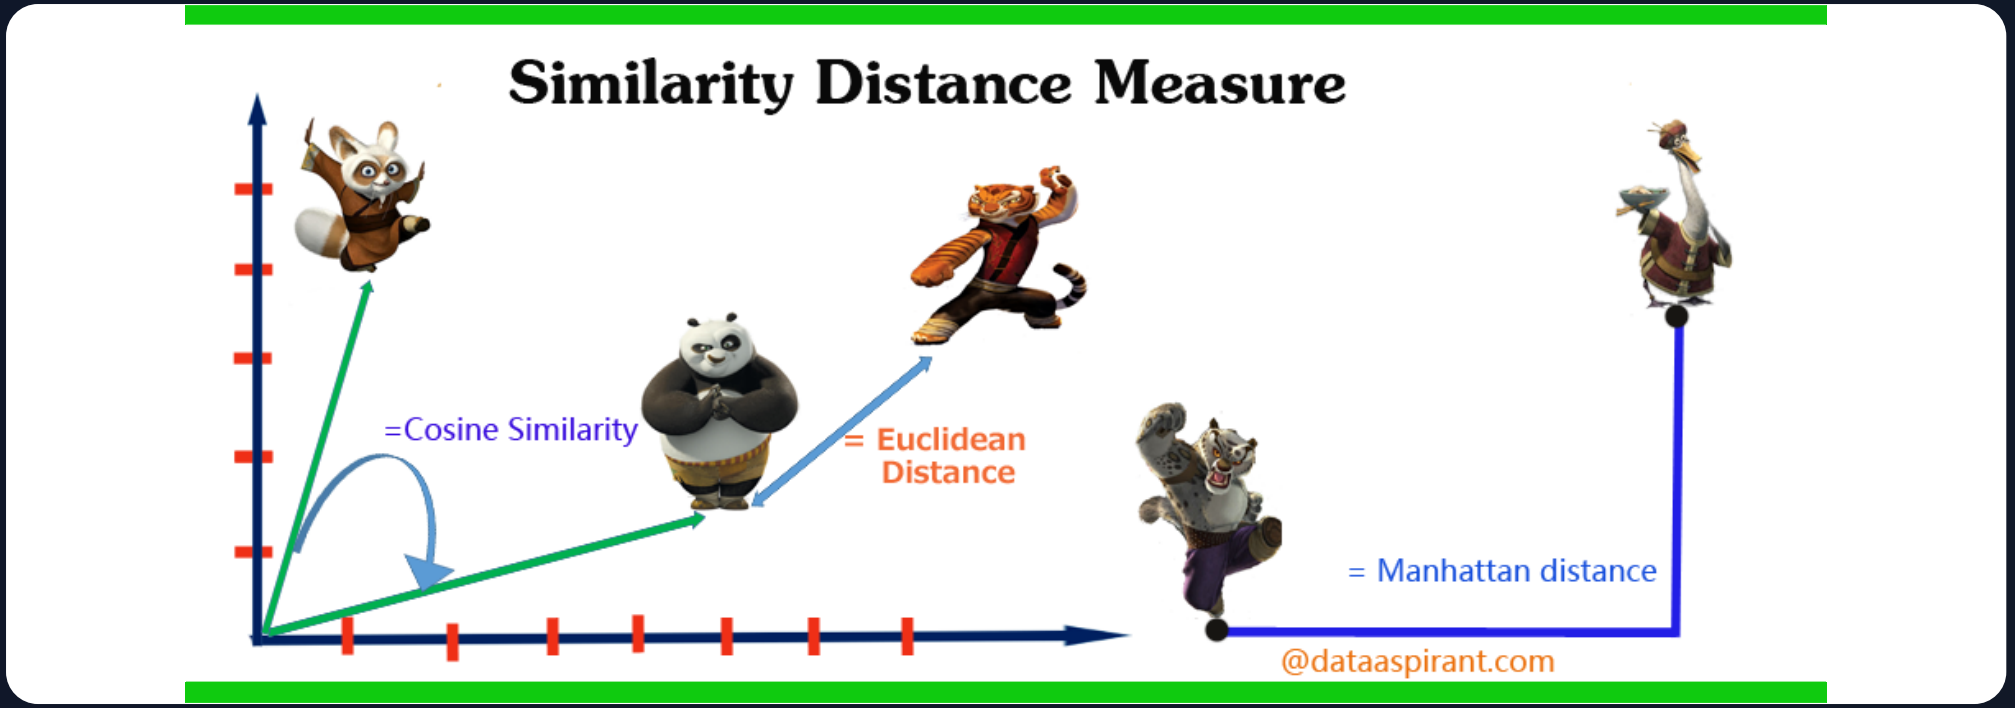
Обычная прямая линия в пространстве признаков. Самый частый выбор.

Манхэттенское

Сумма модулей разностей по координатам. Устойчивее к выбросам.

Косинусное

Угол между векторами. Полезно для текстов и разреженных данных.



Масштаб признаков снова важен

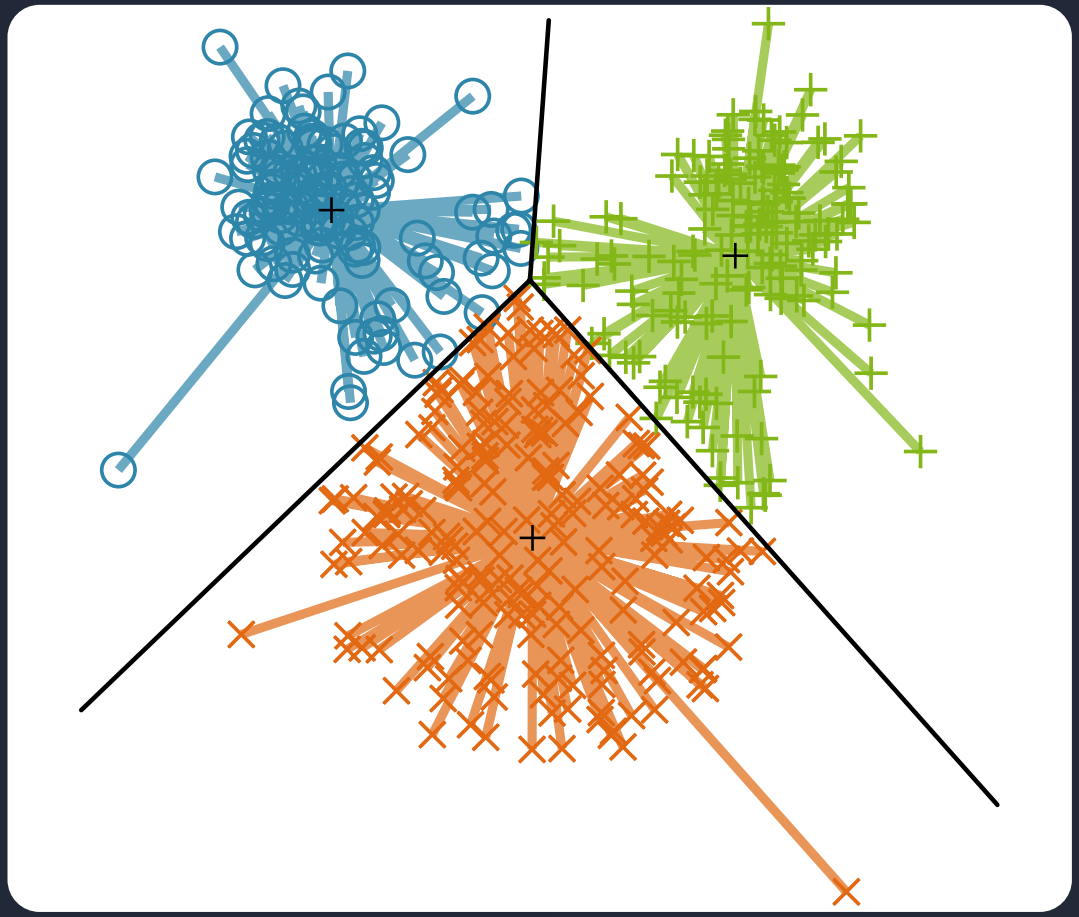
- Расстояния чувствительны к масштабу признаков — как и в kNN из занятия 2.
- Признак с большим разбросом будет доминировать в расстоянии.
- Поэтому перед кластеризацией признаки обычно стандартизируют.

```
StandardScaler → кластеризация
```

KMeans: идея

Основная мысль

- Задается число кластеров k.
- У каждого кластера есть центр (центроид).
- Объект относится к кластеру с ближайшим центроидом.
- Центроиды уточняются по данным итеративно.



Точки данных и центроиды кластеров на плоскости

KMeans: шаги алгоритма

1. Инициализировать k центроидов.
2. Отнести каждый объект к ближайшему центроиду.
3. Пересчитать центроиды как средние по своим кластерам.
4. Повторять шаги 2–3 до стабилизации.

Алгоритм минимизирует суммарное квадратичное расстояние объектов до центров их кластеров.

KMeans: выбор числа кластеров

- Число k задается заранее — это главный недостаток.
- Эвристика «локоть»: по графику внутрикластерного расстояния от k.
- Силуэтный коэффициент (Silhouette score): сравнение разных k.
- Лучший ориентир — смысловая интерпретируемость кластеров.

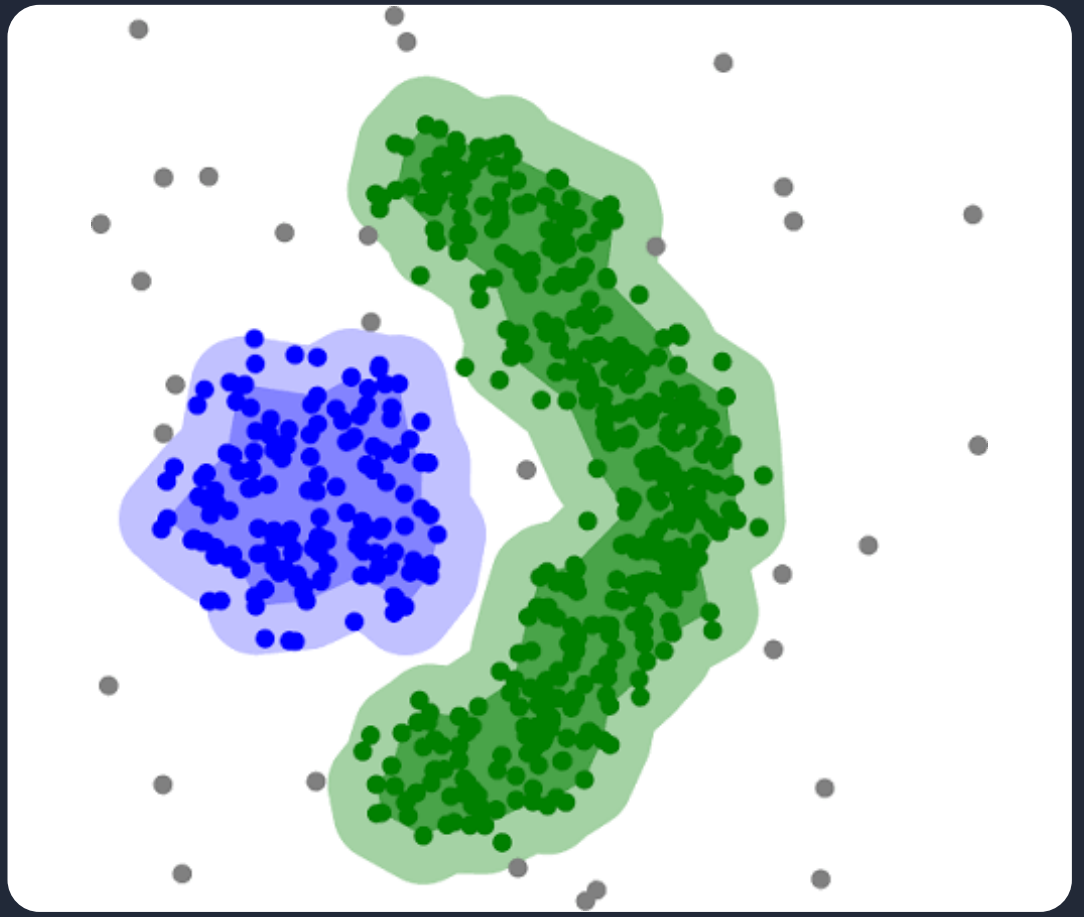
KMeans: ограничения

- Хорошо работает на компактных «шаровидных» кластерах похожего размера.
- Плохо справляется с кластерами сложной формы.
- Чувствителен к инициализации центроидов.
- Чувствителен к выбросам: центроид тянется к шуму.

DBSCAN: идея

Кластеры как области плотности

- Кластер — это плотная область точек.
- Параметр eps: радиус окрестности.
- Параметр min_samples: сколько точек нужно в окрестности.
- Число кластеров определяется само.



Кластеры произвольной формы и шумовые точки

DBSCAN: типы точек

Основные (core)

В окрестности радиуса eps не меньше min_samples точек.

Граничные (border)

Не основные, но попадают в окрестность основной точки.

Шум (noise)

Не попали ни в один кластер. Побочный бонус: поиск выбросов.

DBSCAN: плюсы и минусы

Плюсы

- Находит кластеры произвольной формы.
- Не требует задавать число кластеров.
- Выделяет шумовые точки.

Минусы

- Чувствителен к выбору eps и min_samples.
- Плохо работает при разной плотности кластеров.
- В высокой размерности плотности оцениваются плохо.

Иерархическая кластеризация (обзорно)

- Объекты последовательно объединяются в дерево кластеров — дендрограмму.
- Кластеры получаются срезом дендрограммы на выбранном уровне.
- Удобно, когда нужна иерархия групп, а не плоское разбиение.
- Вычислительно дороже KMeans на больших данных.

Сравнение методов кластеризации

Метод	Что задаем	Форма кластеров	Шум
KMeans	число кластеров k	компактные, шаровидные	не выделяет
DBSCAN	eps, min_samples	произвольная	выделяет как noise
Иерархическая	уровень среза дендрограммы	зависит от меры связи	частично

Оценка качества кластеризации

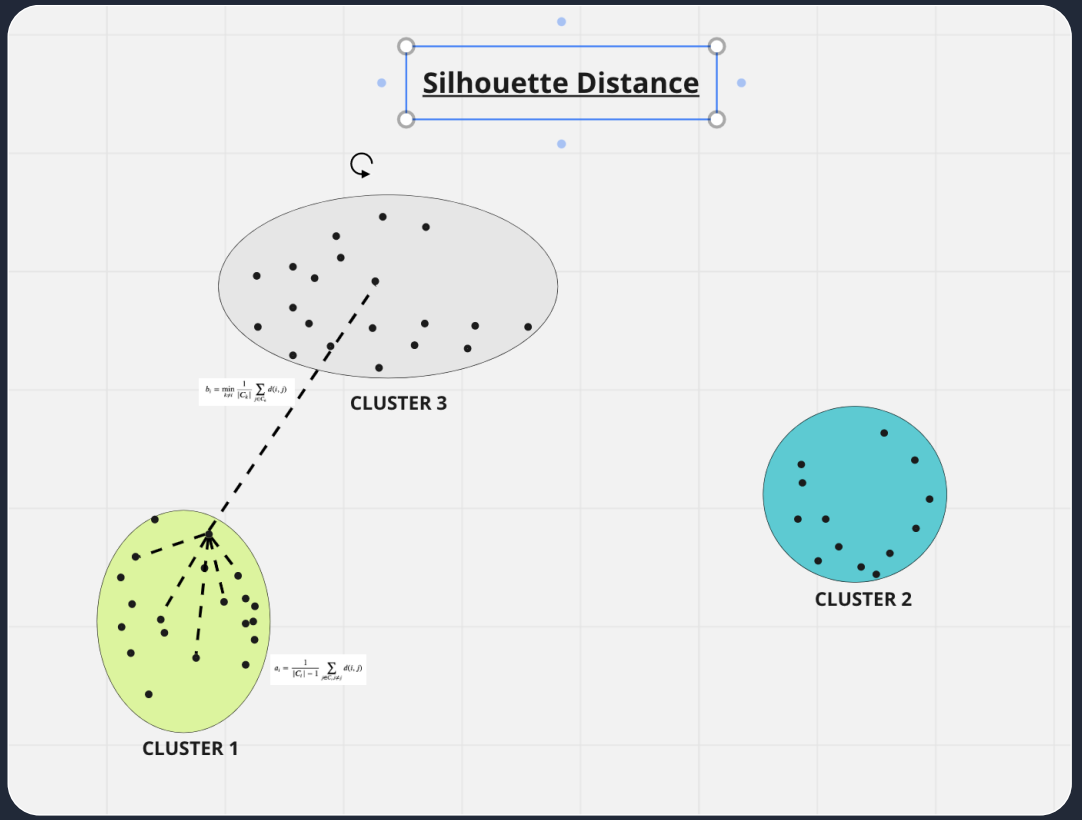
- Правильных ответов нет — сравнить с «истиной» обычно нельзя.
- Внутренние метрики: насколько кластеры плотные и разделимые.
- Внешние метрики: только если есть экспертная разметка для сверки.
- Главный критерий на практике — интерпретируемость и полезность.

Силуэтный коэффициент

Формула для объекта

```
s = (b - a) / max(a, b)
```

- a — среднее расстояние до своих.
- b — среднее расстояние до ближайшего чужого кластера.
- Значения от -1 до 1: ближе к 1 — кластеризация удачная.



Пример силуэтного профиля кластеров

Визуальный осмотр и интерпретация

- Проецируем данные в 2D (PCA / t-SNE / UMAP) и смотрим на кластеры.
- Проверяем, осмысленны ли кластеры: чем отличаются их объекты?
- Сравниваем средние значения признаков по кластерам.

Кластер полезен, если его можно содержательно назвать: «ночные события», «крупные клиенты», «скан-активность».

Устойчивость кластеров

- Проверяем кластеризацию на подвыборках и разных сидах.
- Если разбиение сильно меняется — кластеры ненадежны.
- Устойчивость — косвенный признак реальной структуры в данных.

Опасность «красивых, но бессмысленных» кластеров

- Алгоритм найдет кластеры даже в случайном шуме.
- Красивая картинка не доказывает наличие реальной структуры.
- Проверяйте: устойчивость, силуэт, смысловую интерпретацию.

Кластеризация легко создает иллюзию знания там, где его нет.

Кластеризация в задачах безопасности

- Группировка событий и пользователей по поведению: базовые профили.
- Выделение типов трафика и типов запросов к ИИ-системе.
- Подготовка структуры данных для дальнейшего анализа и мониторинга.

Снижение размерности: зачем

- Визуализация: человек воспринимает 2–3 измерения.
- Сжатие признаков: меньше памяти и быстрее модели.
- Подавление шума и коррелирующих признаков.
- Подготовка данных для других моделей.

Проклятие размерности (кратко)

- В высокой размерности расстояния между объектами становятся менее различимыми.
- Объем пространства растет экспоненциально, данных «не хватает».
- Метрические методы (kNN, кластеризация) деградируют.

Снижение размерности — один из способов бороться с этим эффектом.

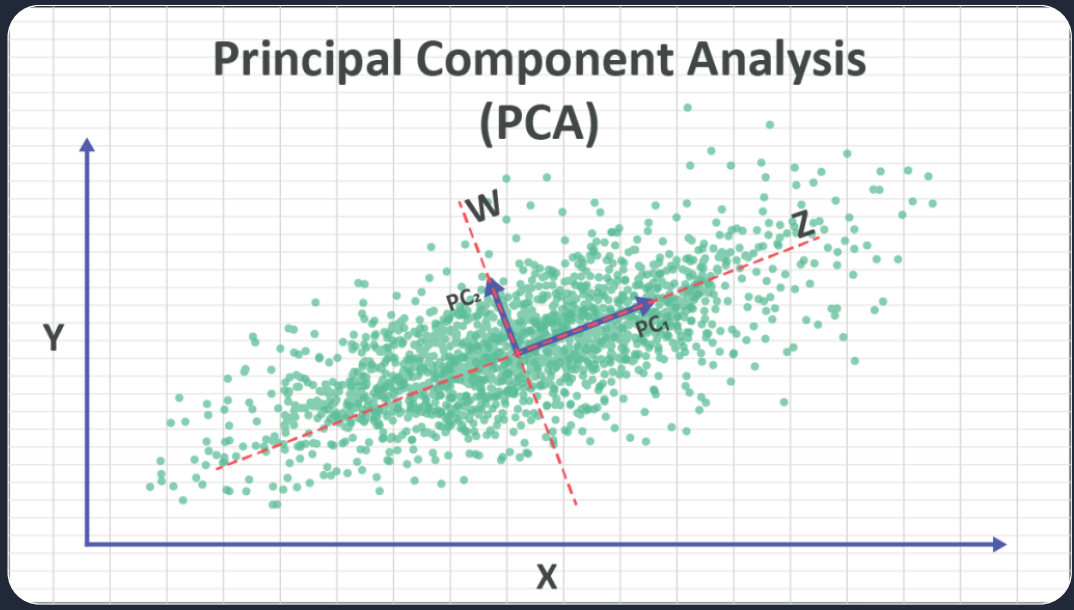
Потеря информации и компромисс

- Проекция в меньшее число измерений неизбежно теряет часть информации.
- Вопрос: сколько компонент оставить и сколько дисперсии сохраняется?
- Слишком мало компонент — теряем структуру; слишком много — не упрощаем.

PCA: идея

Главные компоненты

- Ищем направления наибольшей изменчивости данных.
- Компоненты ортогональны друг другу.
- Первая компонента объясняет больше всего дисперсии.
- Проецируем данные на первые компоненты.



Облако точек и оси главных компонент

PCA: объясненная дисперсия

- У каждой компоненты есть доля объясненной дисперсии.
- Смотрим накопленную кривую: сколько компонент дают, например, 90% дисперсии.
- Для визуализации обычно берут 2 компоненты, даже если дисперсии меньше.

```
explained_variance_ratio_ → cumulative sum
```

PCA: шаги (концептуально)

1. Стандартизовать признаки.
2. Оценить ковариационную структуру данных.
3. Найти собственные направления (главные компоненты).
4. Спроецировать данные на выбранные компоненты.

В sklearn это две строки: fit_transform и transform.

PCA: применения

Визуализация

2D-проекция многомерных данных для осмотра и отчета.

Сжатие

Меньше признаков при сохранении большей части дисперсии.

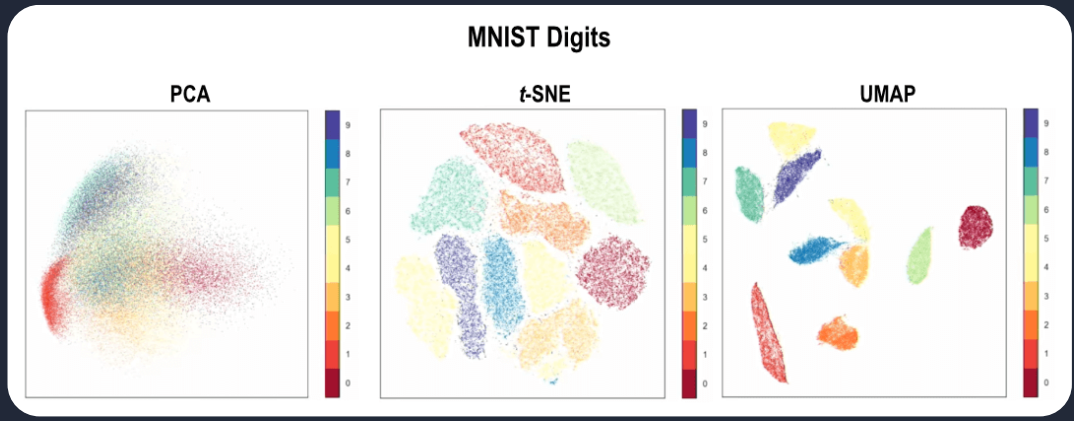
Предобработка

Декорреляция признаков перед другими моделями.

t-SNE (обзорно)

Особенности

- Нелинейный метод для визуализации.
- Хорошо сохраняет локальные окрестности: близкие точки остаются близкими.
- Чувствителен к параметру perplexity и сиду.
- Расстояния между далекими кластерами не интерпретируются.



Одна и та же выборка: проекция PCA и проекция t-SNE

UMAP (обзорно)

- Нелинейный метод визуализации на основе топологии данных.
- Обычно быстрее t-SNE на больших выборках.
- Часто лучше сохраняет глобальную структуру, чем t-SNE.
- Тоже требует аккуратной интерпретации: это проекция, не расстояния.

TriMAP и PaCMAP (обзорно)

TriMAP

Оптимизирует расположение по тройкам точек; акцент на глобальной структуре проекции.

PaCMAP

Сохраняет и локальную, и глобальную структуру за счет парных и соседних связей.

Для первого знакомства достаточно знать, что это современные альтернативы t-SNE/UMAP для визуализации.

Сравнение методов снижения размерности

Метод	Тип	Что сохраняет	Основное применение
PCA	линейный	глобальную дисперсию	сжатие, предобработка, обзор
t-SNE	нелинейный	локальные окрестности	красивая визуализация кластеров
UMAP	нелинейный	локальное + частично глобальное	визуализация больших данных
TriMAP / PaCMAP	нелинейные	баланс локального и глобального	визуализация сложных структур

Осторожно с интерпретацией проекций

- Оси t-SNE/UMAP не имеют смысла сами по себе.
- Расстояния между далекими кластерами на проекции не значимы.
- Разные сиды и параметры дают разные картинки.
- Проекция — инструмент разведки, а не доказательство.

Аномалии: определение

- Аномалия — объект, заметно отличающийся от большинства данных.
- Аномалии редки: их мало относительно нормальных объектов.
- Заранее известных примеров аномалий обычно нет.

```
нормальное поведение ≠ подозрительное поведение
```

Почему аномалии важны для безопасности

- Атаки и вторжения выглядят как отклонения от нормы.
- Мошеннические операции редки и непохожи на обычные.
- Сбои систем и деградация моделей проявляются как аномалии данных.
- Отравление данных и аномальные запросы к ИИ-системе — тоже выбросы.

Чем поиск аномалий отличается от кластеризации

Кластеризация

- Цель — группы похожих объектов.
- Интересует структура большинства.

Поиск аномалий

- Цель — редкие отличающиеся объекты.
- Аномалии могут не образовывать кластер вовсе.

Подходы к поиску аномалий

Статистические

Объект аномален, если маловероятен по модели распределения данных.

На расстояниях

Аномалия далеко от основной массы объектов.

На плотности

Аномалия находится в области низкой локальной плотности.

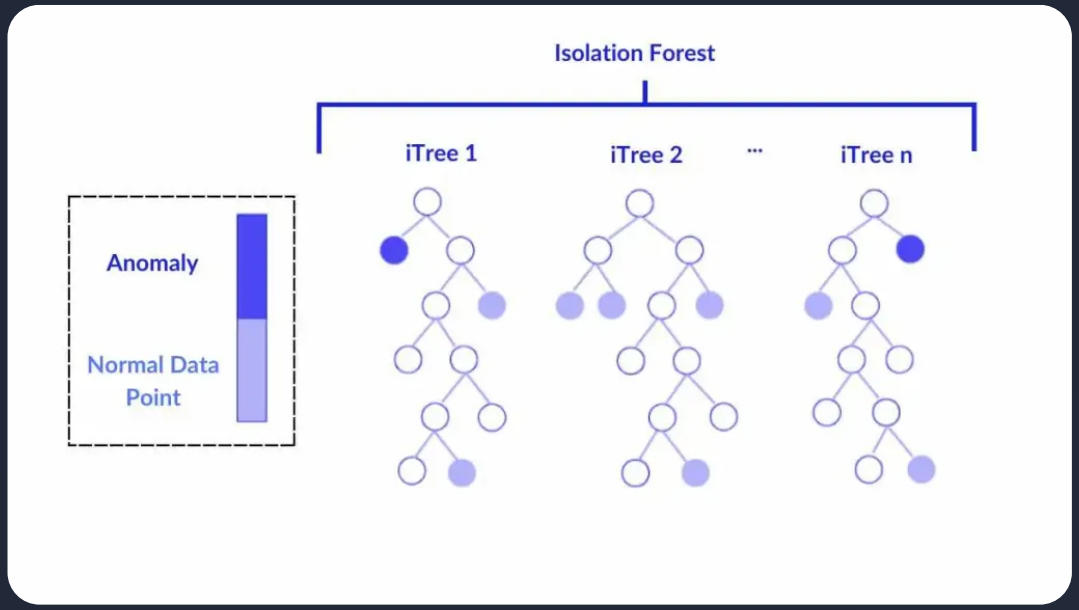
Изолирующие

Аномалию легко отделить от остальных случайными разбиениями.

Isolation Forest: идея

Как работает

- Строится лес случайных деревьев разбиений.
- Аномалии изолируются быстрее: путь в дереве короче.
- Короткая средняя длина пути → высокий score аномальности.



Нормальную точку трудно отделить, аномалию — легко

Local Outlier Factor (LOF)

- Сравнивает локальную плотность объекта с плотностью его соседей.
- LOF около 1 — объект в нормальной плотности.
- LOF заметно больше 1 — объект в разреженной области относительно соседей.
- Хорошо ловит локальные выбросы, а не только глобальные.

One-Class SVM (обзорно)

- Учим модель только на нормальных данных.
- Модель отделяет область «нормы» от остального пространства.
- Объекты вне области нормы помечаются как аномалии.
- Чувствителен к параметрам ядра и доле ожидаемых выбросов.

Score, порог и дисбаланс

- Методы возвращают score аномальности, а не готовый вердикт.
- Порог — бизнес-решение: сколько ложных тревог допустимо.
- Аномалий мало, поэтому accuracy бесполезна: смотрим precision/recall редкого класса.

Связка с занятием 2: те же метрики, но на сильно несбалансированных классах.

Метрики поиска аномалий

- Precision и recall по классу аномалий.
- F1 как баланс.
- PR-AUC: качество ранжирования аномалий наверх списка.
- Если разметки нет — оцениваем на экспертных кейсах и устойчивости.

Связь с MLSecOps

- Поиск подозрительной активности в логах и трафике.
- Мониторинг дрейфа данных: распределение входов меняется со временем.
- Обнаружение нестандартных входных данных для модели (out-of-distribution).
- Выявление аномальных запросов к ИИ-системе, включая попытки злоупотребления.
- Аномалия как ранний сигнал инцидента безопасности.

Практика: что будем делать

Кластеризация и размерность

- make_blobs, Iris и Wine без меток.
- KMeans и DBSCAN: сравнение результатов.
- PCA: проекция в 2D и объясненная дисперсия.

Аномалии

- Генерируем нормальные данные и выбросы.
- Isolation Forest и Local Outlier Factor.
- Смотрим, какие объекты помечены как аномальные.

Итоги занятия

- Без учителя мы ищем структуру, а не предсказываем ответ.
- KMeans прост, но требует k и любит компактные кластеры; DBSCAN находит формы и шум.
- Качество кластеризации оцениваем осторожно: силуэт, устойчивость, смысл.
- PCA сжимает и визуализирует; t-SNE/UMAP/TriMAP/PaCMAP — инструменты разведки.
- Поиск аномалий — мост между ML и безопасностью: дрейф, OOD-входы, подозрительные события.

Следующий шаг: практика в ноутбуке — кластеризация, PCA и обнаружение аномалий на реальных данных.